آخرین فرصت تحویل: ۱۹ اردیبهشت

تمرین دوم

دانشکده مهندسی و علوم کامپیوتر

درس بازیابی اطلاعات استاد: دكتر نشاطي ترم دوم سال تحصیلی ۹۸/۹۹

مقدمه

هدف از این پروژه، آشنایی بیشتر شما با ابزار الستیک و همینطور چالش های جدی تر، هنگام کار با ابزارهای بازیابی اطلاعات می باشد.

خو استه ها

در این تمرین شما میبایست با مراجعه به بخش آرشیو سایت خبری عصر ایران به این آدرس، اخبار مربوط به تاریخ های بین ۱ فروردین تا ۲۸ فروردین را استخراج کرده و اطلاعات مرتبط با هر خبر را در یک دیتاست آماده کنید.



همانطور که در تصویر بالا مشخص شده است، هر خبر شامل بخش هایی از جمله کد خبر، تاریخ انتشار، موضوع، عنوان، خلاصه ی خبر(در نظر داشته باشید که این بخش، برای همه ی خبرها، وجود ندارد)، ، متن خبر، لینک کوتاه و برچسب می باشد. برای جست و جو می توانید از صفحه ی ارشیو این سایت که در تصویر پایین مشاهده می شود، استفاده کنید.



شما در این تمرین، ابتدا باید یک کد کرولر بنویسید که با گرفتن دو تاریخ از کاربر، اقدام به کرول کردن این سایت خبری بکند و دیتاستی که خواسته شده را ایجاد کند. شما دیتاست ایجادی را باید در سایت mega.nz آپلود کرده و لینک مربوط به آن را در گزارش این تمرین ارسال کنید. همچنین سورس کدی که برای کرول کردن نوشته اید را نیز باید ارسال بکنید. در صورتی که کرول شما قبل از کرول کردن، بتواند نوع موضوع را از کاربر دریافت کند، نمره ی امتیازی خواهد داشت.

پس از ایجاد این دیتاست، شما باید ورودی را به برنامه ی الاستیک خود وارد کنید و سپس اسناد مرتبط با کوئریهای زیر را بیان نمایید:(محل رخداد در متن خبر)

- ١- لَنترنُت
- ۲- محدودیتهایی
- ۳- حدود ۶,۷ درصد
- ۴- درمان سخت تر خواهد بود و در ادامه افراد بیشتری به بخش های مراقبتهای
 - ۵- **2018**بیش از **118** میلیارد دلار (67 میلیارد یوند)
 - ۶- آمایت مهتانی
 - ٧- سريلانكا

كد اخبار مرتبط با ارقام زير را بيان نماييد:

- ۱- ۱۲ (در تاریخ خبر)
 - ۲- 13(در تاریخ خبر)

متن پیشنهادی سیستم در صورت نوشتن موارد زیر را بیان نمایید:

- **١** بيل د بلا
- ۲- تعطیلی مدارس نیویورک تا پایان
 - ٣- اسماعيل لله گني
 - ۴- کتاد
- ۵- تنی چند از مدیران عامل بانک ها برگذار شد
 - ۶- استعفای وزیر هنر استرالیا پس از

شما باید دقیقا کلمات بالا را جستجو نمایید و محل رخداد کلمه و عنوان سند و لینک خبر را بیان نمایید. (در فرآیند تصحیح موارد مشابه نیز تست و بررسی خواهند شد)

برای ایندکس کردن میبایست از ابزار زیر استفاده نمایید:

https://github.com/NarimanN2/ParsiAnalyzer

سیستم شما باید قابلیت تصحیح کوئری(غلط املایی) و پیشنهاد کوئری را داشته باشد.

کد خود را(کد باید تکمیل باشد به نحوی که خودش ایندکس را ساخته تنطیمات را اعمال کرده و کرول و ایندکس نماید) را به همراه مستندات و گزارشی از نحوه افزودن این ویژگی ها به آن و شمار اسناد یافت شده برای سوالات ارسال نمایید.

نكات مهم

- پروژه به صورت انفرادی انجام خواهد گرفت.
- تحویل دادنی های شما، علاوه بر گزارش نتایج پاسخ ها، شامل سورس کد دو برنامه ی کرولر و برنامه ی بازیابی کننده ی اطلاعات می باشد.
- این پروژه <u>تحویل حضوری</u> دارد و گرفتن نمره ی کامل، منوط به حضور در جلسه ی تحویل و تسلط بر روی کد می باشد که زمان آن متعاقبا اعلام خواهد شد. در این جلسه شما باید کدی که در کورس ویر آپلود کردید را بر روی رایانه ی خود، مجددا کامپایل کرده و از برنامه خروجی بگیرید. همچنین باید بر روی کد مسلط باشید. دقت داشته باشید که عدم شرکت در این جلسه در صورت تشکیل، موجب از دست دادن درصد زیادی از نمره خواهد شد.
 - برای برنامه نویسی از هر زبانی که دوست داشته باشید، میتوانید استفاده کنید.
 - تمیزی و خوانایی کد، نمره اضافی خواهد داشت.
- مشورت با دوستان بلامانع است ولی در صورت تقلب و استفاده از کد دیگران، <u>در صورت تشخیص</u> موجب کسب نمره ی -۱۰۰۰٪ برای طرفین خواهد شد.
- ســورس برنامــه ی خــود را بــه همـــراه فایـــل اجرایـــی آن، بــه صــورت zip شــده بــا فرمــت
 IR_HW2_{studentNO}.zip بر روی کورس ویر آپلود کنید.
- دقت بکنید که در صورتی که از زبان جاوا استفاده میکنید، فایل sava.* و یا class.* یک فایل خروجی محسوب نمی شود و باید یک فایل ar.* به عنوان فایل اجرایی بفرستید.
- در صورتی که از زبان پایتون استفاده می کنید، حتما باید پکیج هایی که استفاده کردید را در فایل requirements.txt ذخیره کرده باشید. همچنین در مستندات خود به ورژن پایتونی که استفاده کرده اید، اشاره کنید.
 - ترجیحا ازآخرین ورژن elasticsearch استفاده نمایید.
- در صورت داشتن هرگونه سوال مرتبط با این پروژه، می توانید با ایمیل <u>Omidomk1@gmail.com</u> در ارتباط باشید. لطفا در نظر داشته باشید که سوال هایتان را نهایتا تا سه روز مانده به ددلاین مطرح کنید، چرا که پس از آن احتمال پاسخ به شما بسیار کم می باشد.

با آرزوی موفقیت و سربلندی سینا تمجیدی